

Retrieval-Augmented Generation, ou RAG, combina busca por similaridade vetorial com geracao de texto via LLM. O documento e quebrado em pedacos menores chamados chunks, cada chunk vira um vetor numerico atraves de um modelo de embeddings, e esses vetores sao armazenados em um banco de dados vetorial como o Neo4j. Quando o usuario faz uma pergunta, o sistema converte a pergunta em um vetor e busca os chunks mais similares no banco. Esses chunks formam o contexto que e enviado junto com a pergunta para o modelo de linguagem, que gera a resposta final baseada apenas no contexto recuperado. Este e um documento placeholder gerado automaticamente para validar o pipeline de indexacao antes que um documento real seja fornecido. Substitua data/source.pdf pelo seu proprio PDF quando quiser.